P1 | Classificador de temas legislativos

MVP de Machine Learning • Dificuldade: baixa–média

O que você vai construir

Uma aplicação que recebe a ementa ou o texto de uma proposição legislativa e indica o tema mais provável (por exemplo, educação ou saúde). O modelo aprende com proposições já classificadas pela Câmara dos Deputados.

Resultado esperado

- Um modelo de classificação de texto treinado e comparado com uma alternativa.
- Uma API FastAPI com POST /predict e GET /health.
- Testes automatizados, execução por Docker e resultados documentados no GitHub.

Dados e ferramentas

- Fonte: Dados Abertos da Câmara dos Deputados (ementas/textos e classificação temática oficial).
- Recorte: 5 a 10 temas com quantidade suficiente de exemplos; documente período, data da coleta e distribuição de classes.
- Stack: Python, pandas, scikit-learn, FastAPI, pytest, Docker e MLflow para registrar experimentos.

Passo a passo

- 1. Coletar: baixar proposições com ementa e tema; guardar os dados brutos e registrar a origem.
- 2. Preparar: remover duplicatas, registros sem texto e rótulos inconsistentes; conferir desbalanceamento.
- 3. Separar: criar treino, validação e teste antes de ajustar o modelo; evitar que o mesmo texto apareça em conjuntos diferentes.
- 4. Baseline: transformar texto com TF-IDF e treinar Logistic Regression.
- 5. Comparar: testar pelo menos outro algoritmo (ex.: Linear SVM) usando a mesma validação; escolher com base nas métricas.
- 6. Avaliar: medir no teste reservado uma única vez; analisar manualmente 20–30 previsões erradas.
- 7. Servir: salvar pipeline e modelo; criar /predict e /health; testar entrada válida e inválida.
- 8. Empacotar: criar Dockerfile, testes e comando para reproduzir o treinamento.

Como avaliar

Métrica principal: macro-F1 (trata todas as classes com o mesmo peso). Mostre também precisão e recall por tema, matriz de confusão e, quando fizer sentido, balanced accuracy ou PR-AUC.

Modelo	Macro-F1 no teste	Observação
TF-IDF + Logistic Regression	Preencher após medir	Baseline
TF-IDF + segundo algoritmo	Preencher após medir	Modelo comparado

Exemplo de uso

Entrada: “Dispõe sobre o acesso à educação básica nas escolas públicas.”
Saída ilustrativa: {"tema": "Educação", "confianca": 0.82}
O número é apenas exemplo de formato, não resultado medido.

Checklist de pronto

- [ ] Treinamento reproduzível por um comando, com dados e dependências documentados.
- [ ] Baseline e segundo modelo comparados no mesmo protocolo.
- [ ] Métricas reportadas no teste separado, sem resultados inventados.
- [ ] Testes cobrem preparação de texto e endpoint; API funciona em Docker.
- [ ] README contém instruções, tabela de métricas, limitações e GIF curto de demonstração.

Se sobrar tempo (opcional)

Experimentar embeddings ou um encoder em português. Só vale avançar se o MVP básico estiver concluído.

Fonte principal

Relatório anexado, seção “P1 — Classificador de temas legislativos + API” (p. 9). Dados oficiais: https://dadosabertos.camara.leg.br/